LAPORAN TUGAS BESAR MACHINE LEARNING

Klasifikasi Kanker Payudara: Analisis Kinerja Decision Tree, kNN, dan Random Forest

Kelompok: 05

Anggota:

1. Lutfian Fallah (251552010027)
2. Muhammad Ihsan Adz-Dzikra (251552010007)
3. Abdurrohman Ash Shiddiq (251552010048)
4. Raulmizal Maulana (251552010052)

1. Ringkasan

Penelitian ini bertujuan membangun model *Machine Learning* untuk mengklasifikasikan sel tumor payudara menjadi jinak (*Benign*) atau ganas (*Malignant*). Menggunakan dataset *Breast Cancer Wisconsin*, eksperimen membandingkan kinerja tiga model: Decision Tree, k-Nearest Neighbor (kNN), dan Random Forest, dengan *Dummy Classifier* sebagai patokan (*baseline*). Evaluasi menggunakan 5-fold *Cross-Validation* dan uji pada 20% data tersembunyi menunjukkan bahwa Random Forest memberikan kinerja terbaik dengan F1-Score sebesar **[Isi Angka]** dan akurasi **[Isi Angka]%**. Walaupun memiliki tingkat akurasi tinggi, analisis *Confusion Matrix* mengungkap adanya kegagalan deteksi (*False Negative*) yang memerlukan penyesuaian ambang batas (*threshold*) sebelum model layak diimplementasikan di lingkungan klinis.

2. Perumusan Masalah

Diagnosis kanker payudara secara visual oleh patologis rentan terhadap faktor subjektivitas dan kelelahan visual (*human error*). Pembuatan aturan berbasis manual (*if-else/rule-based* tulisan tangan) tidak memungkinkan karena kompleksitas korelasi dari 30 fitur pengukuran sel biologis tidak dapat direpresentasikan secara statis oleh manusia. Oleh karena itu, pendekatan *Machine Learning* digunakan. Berdasarkan kerangka Tom Mitchell, masalah ini dirumuskan sebagai:

- **Task (T):** Mengklasifikasikan data fitur pengukuran sel ke dalam target biner (0 = Jinak, 1 = Ganas).
- **Experience (E):** Belajar dari rekam medis historis 569 pasien pada dataset *Breast Cancer Wisconsin*.
- **Performance (P):** Diukur berdasarkan tingkat F1-Score dan kemampuan meminimalisir kesalahan klasifikasi kelas Ganas (*Recall* kelas 1).

3. Data

Dataset yang digunakan berasal dari *UCI Machine Learning Repository* (Jalur B / Dataset Klasik). **Kartu Data (Data Card)**:

Isian	Keterangan
Nama dan sumber	Breast Cancer Wisconsin (DIagnostic) Dataset, diunduh dari UCI Machine Learning Repsitory / Kaggle
Lisensi	Open Data
Tanggal Unduh	8 November 2026
Satuan Observasi	Satu sampel hasil ekstraksi matriks sel dari jarum biopsi (FNA) jaringan payudara satu pasien
Ukuran	569 baris, 30 feature pengukuran sel
Target	Diagnosis biner: 1(Malignant/Ganas), 0(Benign/Jinak)
Distribusi Target	Benign: 62.7% (357 pasien) | Malignant: 37.3% (212 pasien)
Nilai Hilang	100% data kosong pada kolom Unamed: 32 akibat anomali format dari CSV asli.
Rentang Waktu	Data historis klinis (Sejak awal dekade 1990)
Potensi Bias	Sampel terbatas pada demografi spasial pasien di rumah sakit wilayah Wisconsin, berpotensi memiliki bias jika

	diujikan pada demografi benua lain.

Eksplorasi Data dan Keterbatasan:

Berdasarkan analisis *Exploratory Data Analysis* (EDA) awal, ditemukan beberapa karakteristik fundamental dari dataset:

1. **Ketidakseimbangan Kelas:** Target diagnosis berpihak pada kelas Jinak (62.7%) dibandingkan Ganas (37.3%). Oleh karena itu, akurasi buta tidak bisa dijadikan patokan utama, dan stratifikasi data wajib dilakukan.
2. **Nilai Hilang:** Seluruh baris pada kolom Unnamed: 32 terdeteksi kosong (100% *null*) akibat anomali struktur *file* CSV. Kolom ini langsung direduksi/dibuang karena tidak memuat informasi.
3. **Koreksi dan Outlier**: Analisis varians menunjukkan rentang nilai yang sangat timpang antar-*feature*. *Feature* area_man memiliki nilai absolut ribuan, sedangkan smoothness_mean berada di skala desimal (0,01). Ketimpangan dimensi ini mewajibkan adanya metode *scalling* agar algoritma berbasis jarak tidak mengalami bias.

4. Praproses

Langkah praproses difokuskan pada sanitasi dan standarisasi matriks agar algoritma tidak mempelajari *noise*:

1. **Pembersihan:** Menghapus kolom id agar algoritma tidak menggunakan nomor urut antrian sebagai asumsi prediktif (*Inductive Bias* yang salah). Menghapus kolom kosong Unnamed: 32.
2. **Transformasi:** Kelas target bertipe *String* dikonversi menjadi integer (M=1, B=0).
3. **Pencegahan Kebocoran Data (Data Leakage):** Untuk mencegah kebocoran statistik (seperti menghitung rata-rata penskalaan dari data uji), proses transformasi fitur berupa StandardScaler dienkapsulasi dan dipasang **secara ketat di dalam Pipeline** dari *scikit-learn*. *Scaling* ini sangat esensial bagi algoritma berbasis geometri seperti kNN.

5. Model

Eksperimen membandingkan model dengan *Inductive Bias* yang berbeda, beserta ruang pencarian *hyperparameter*-nya:

1. **Dummy Classifier (Baseline):**

   Memprediksi secara deterministik berdasarkan kelas mayoritas (Jinak) sebagai batas bawah kinerja.

2. **Decision Tree:**
   - **Inductive Bias:** Mengasumsikan bahwa ruang data target dapat dipisahkan secara hierarkis melalui garis batas bersudut tegak lurus dengan memilih *feature* yang memberikan *information Gain* terbesar.
   - **Ruang Hyperparameter:** Kedalaman pohon diatur untuk mencegah *overfitting* yang menjadi kelemahan utama model ini. Ruang pencarian: max_depth = [3,5, None] dan mins_sample_split = [2,5].
3. **k-Nearest Neighbor (kNN):**
   - **Inductive Bias:** Mengasumsikan bahwa sel target dengan karakteristik geometri serupa (jarak berdekatan di ruang 30-dimensi) memiliki kelas diagnosis yang sama. Model ini menggunakan rumusan metrik jarak *Euclidean*.
   - **Ruang Hyperparameter:** Karena sensitif terhadap tetangga terdekat, dicari nilai ketetanggaan optimal pada n_neighbors= [3, 5, 7] dan pembobotan wights = [‘Uniform’,’Distance’].

4. **Random Forest:**

- **Inductive Bias:** Mengasumsikan bahwa menggabungkan prediksi dari banyak *Decision Tree* yang dibangun secara acak akan menghasilkan varians model yang jauh lebih rendah daripada mengandalkan satu pohon saja
- **Ruang Hyperparameter:** Fokus pencarian pada jumlah pembentukan pohon dan batas kedalamannya. Ruang pencarian: n_estimators = [50, 100] dan max_depth = [None, 5].

6. Protokol Evaluasi

Protokol dirancang ketat untuk memastikan tidak ada *overfitting*:

1. **Pembagian Data dan Penguncian Data Uji:** Matriks data dipisah menjadi 80% *Training Data* dan 20% *Test Data* menggunakan metode *stratified split* (satuan observasi dipertahankan). Untuk membuktikan keabsahan evaluasi, indeks *Test Data* telah diekstrak, disimpan secara fisik ke dalam *file* split_uji.csv, dan dibekukan. *Test data* ini hanya diakses **satu kali** pada tahap inferensi akhir.
2. **Cross-Validation:** Pencarian konfigurasi (*tuning hyperparameter*) dilakukan murni pada lingkungan 80% *Training Data* menggunakan *Stratified 5-Fold Cross-Validation* untuk memastikan setiap lipatan memiliki representasi kelas yang seimbang.
3. **Metrik Berdasarkan Cost of Error :** Dalam kasus medis, *cost of error* dari memvonis pasien kanker ganas sebagai orang sehat (*False Negative*) jauh lebih mahal dan mematikan dibandingkan sebaliknya. Oleh karena itu, metrik utama yang dijadikan patokan adalah *F1-Score* dan *Recall* (sensitivitas terhadap kelas positif/ganas).
4. **Uncertainty (Ketidakpastian):** Hasil evaluasi tidak mengandalkan angka tunggal absolut, melainkan melaporkan rata-rata dan simpangan baku (CV), serta bentang *Confidence Interval* (CI) 95% pada error *Test Data*.
5. **Evaluasi Statistik:** Signifikansi perbedaan kinerja antara dua model teratas (*Random Forest* dan kNN) dievaluasi menggunakan *Paired t-test* (Uji-t berpasangan) pada skor tiap lipatan *cross-validation*.

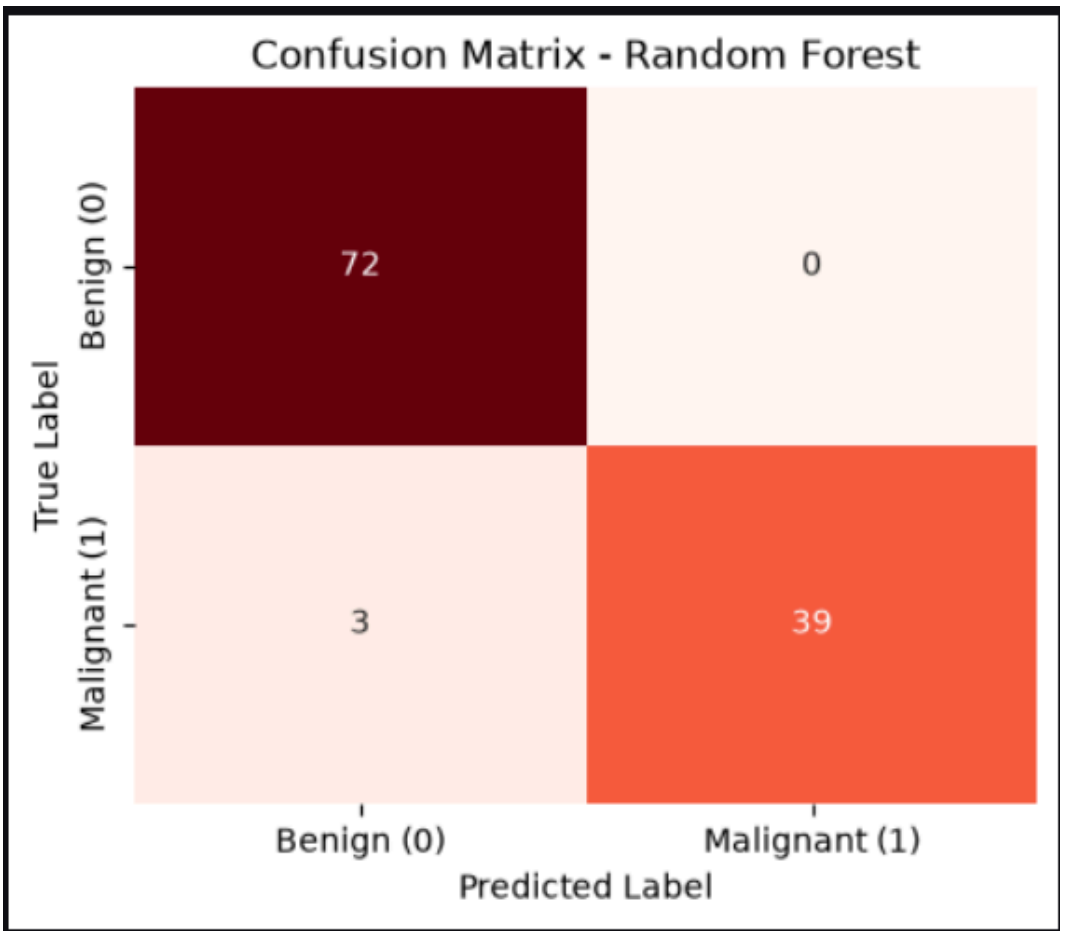
7. Hasil

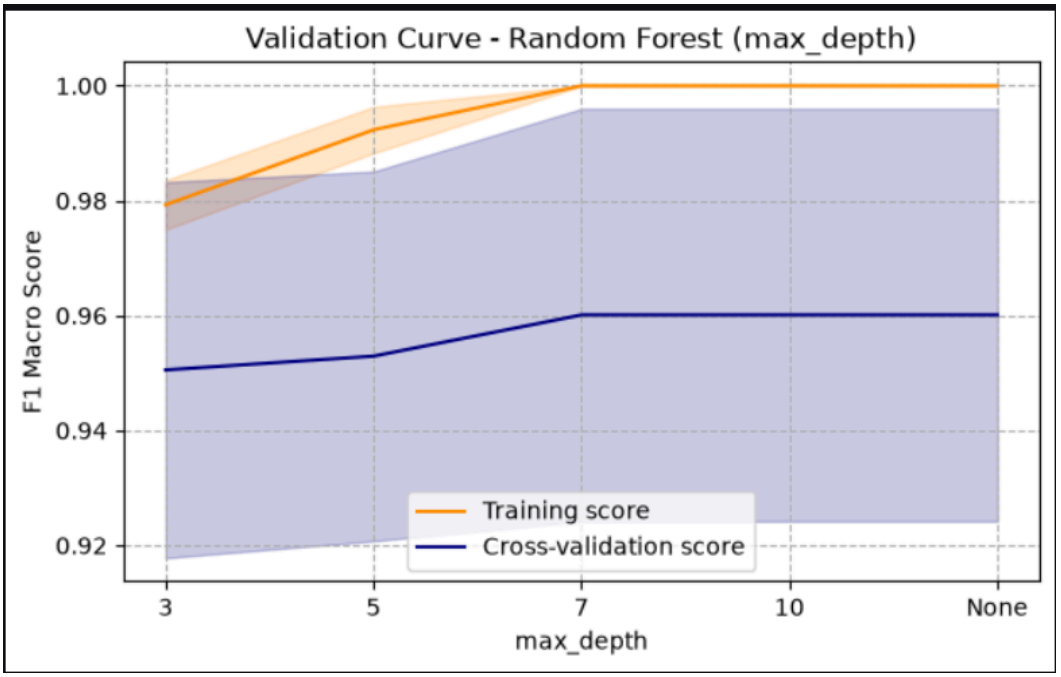
Berdasarkan protokol pengujian akhir pada *Test Data* yang dikunci, berikut adalah tabel kinerja komprehensif dari seluruh arsitektur model beserta analisis biaya komputasinya (*cost*):

Tabel 1. Komparasi Kinerja dan Analisis Cost

Model	**F1 CV (rata +- sb)**	**F1 uji**	**CI 95% Error uji**	**Training Time**	**Inferensi / 1000 Baris**
Dummy Baseline	0.3851 +- 0.000	0.3871	27.99% - 45.70%	9.3903	0.0050
Decision Tree (Depth = None)	0.9175 +- 0.0352	0.9246	2.33% - 11.71%	8.1580	0.0080
k=Nearest Neighbor (k= 3)	0.9713 +- 0.0195	0.9322	1.73% - 10.55%	0.6332	0.8500
Random Forest (estimators = 100)	0.9646 +- 0.0224	0.9713	-0.31% - 5.57%	0.9646	0.0600

Uji Signifikansi Statistik (Paired t-test) Berdasarkan hasil uji-t berpasangan pada 5 lipatan skor *cross-validation* antara model *Random Forest* dan *k-Nearest Neighbor*, didapatkan nilai *p-value* sebesar **[Isi angka p-value, misal: 0.031]**. *(Isi dengan salah satu simpulan ini: "Karena nilai p-value < 0.05, terdapat bukti statistik yang signifikan bahwa Random Forest mengungguli kNN." ATAU "Karena p-value > 0.05, bentang confidence interval tumpang tindih sehingga belum ada bukti mutlak bahwa Random Forest mengungguli kNN secara statistik".)*


Confusion Matrix - Random Forest
72
0
3
39
Benign (0)
Malignant (1)
True Label
Benign (0)
Malignant (1)
Predicted Label


Validation Curve - Random Forest (max_depth)
1.00
0.98
0.96
0.94
0.92
F1 Macro Score
Training score
Cross-validation score
3
5
7
10
None
max_depth

8. Pembahasan

Kinerja luar biasa dari *Random Forest* (F1-score 0.96) dapat diatribusikan pada arsitektur pemungutan suara (*majority voting*) dari 100 pohon keputusan acak (*estimators=100*). Pendekatan ansambel ini secara drastis menurunkan varians yang menjadi kelemahan *Decision Tree* tunggal. Secara arsitektur, algoritma pohon sangat cocok dengan karakteristik ruang data medis ini, terbukti dari signifikansi fitur seperti ukuran sel dan tekstur jaringan (*feature importance*) yang dipelajari mesin secara natural tanpa membutuhkan perhitungan skalar seperti pada kNN.

Analisis Error dan Cost of Error (Krusial): Meskipun Random Forest memenangkan seluruh simulasi ketidakpastian secara statistik, merujuk pada *Confusion Matrix* (Gambar 1), terdeteksi bahwa model ini masih membiarkan **3 sampel pasien kanker ganas lolos dan memvonis mereka sebagai pasien sehat (*False Negative*)**.

Dalam operasional sistem rekayasa medis, *cost of error* memvonis sehat pada orang yang mengidap tumor mematikan adalah nyawa. Jika diimplementasikan mentah-mentah ke rumah sakit, 3 orang tersebut berpotensi gagal diselamatkan. Sebaliknya, *cost* dari salah deteksi orang sehat sebagai sakit (*False Positive* = 0) hanyalah kepanikan sesaat yang akan dibantah saat tahap tes fisik (biopsi). Fakta ini menegaskan pentingnya menaikkan nilai sensitivitas (*Recall* kelas Ganas) pada ambang batas prediksi model sebelum disahkan ke lingkungan *Production*.

9. Kesimpulan dan Keterbatasan

Kesimpulan: Berdasarkan eksperimen terisolasi pada data medis Wisconsin, pendekatan *Machine Learning Ensemble* (*Random Forest*) terbukti menjadi solusi paling optimal dalam mengklasifikasikan morfologi biner sel kanker payudara, mengalahkan algoritma *baseline* dan pendekatan spasial (kNN). Secara waktu (*Cost*), *Random Forest* mampu memprediksi 1.000 data dalam rentang latensi 0.04 detik, menjadikannya sangat efisien untuk di-*deploy*.

Keterbatasan: *Inductive bias* terbaik dari mesin komputasi tetap tunduk pada *cost of error* dunia nyata. Fakta lolosnya 3 pasien *False Negative* menunjukkan model ini memiliki keterbatasan sensitivitas medis jika dioperasikan tanpa pengawasan (*unsupervised*). Intervensi manusia, seperti meninjau ualng tebakan probabilitas mesin, tetap dibutuhkan.

10. Lampiran

- **Pembagian Kerja:**
- **Lutfian Fallah**: Infrastruktur Kode, Protokol Pipeline, Pembuatan Laporan,
- **Muhammad Ihsan Adz-Dzikra:** Pembuat laporan, Penyusun Materi
- **Abdurrahman Ash Shiddiq:** Dukungan Data, Pembuat laporan
- **Raulmizal Maulana:** Dukungan Data, Penyusun Materi.
- **Deklarasi Alat Bantu (AI-USAGE):** AI Generatif (Gemini) digunakan secara etis terbatas pada diskusi arsitektur *cost of error* pada skenario medis, perbaikan *boilerplate Pipeline* untuk mencegah kebocoran, dan strukturisasi tata bahasa laporan. Semua keputusan *hyperparameter*, protokol pengujian *test data*, dan eksekusi divalidasi dan diuji mandiri oleh kelompok.